

Ir Além 1 — IA Generativa e Extração de Informações Clínicas

Chain of Thought aplicado à triagem cardiológica

Curso de Tecnologia em Inteligência Artificial — FIAP | Disciplina: PCV

1. Objetivo

Este documento descreve a implementação da extensão "Ir Além 1", que expande o Assistente Cardiológico Conversacional para interpretar textos clínicos não estruturados, extraindo informações relevantes através de uma técnica de prompting com modelo de linguagem (LLM), conforme apresentado no Capítulo 10 da disciplina. Entre as seis técnicas descritas no capítulo (Role Prompting, Parâmetros de Geração, RAG, Chain of Thought, IA Multimodal e Metodologia CALM), foi escolhida a técnica de Chain of Thought (CoT) como foco desta entrega, conforme orientação do professor de que apenas uma técnica, a mais viável para o projeto, precisaria ser aprofundada.

2. Justificativa da troca de ferramenta (watsonx.ai → Ollama)

O enunciado original sugere o uso do watsonx.ai para esta etapa. Durante o desenvolvimento, a conta IBM Cloud utilizada no projeto foi bloqueada, impossibilitando o acesso ao serviço mesmo após tentativa de recuperação. Diante disso, e com autorização do professor da disciplina para o uso de ferramentas equivalentes mediante justificativa, optou-se pelo uso do Ollama, executando o modelo llama3.1:8b localmente.

Essa escolha se sustenta em três pontos: primeiro, as técnicas de prompting do Capítulo 10 — incluindo Chain of Thought — são conceitos agnósticos de fornecedor, aplicáveis da mesma forma a qualquer LLM que aceite um prompt de texto, seja Watson, OpenAI ou Ollama. Segundo, o Ollama expõe a API de chat de forma direta, sem abstrações prontas de orquestração, o que mantém o foco na técnica de prompting em si, evitando o uso de uma ferramenta que já entregasse pronto o comportamento avaliado — preocupação explicitamente levantada pelo professor. Terceiro, o Ollama já era utilizado em projeto anterior da disciplina (RAG jurídico), sem dependência de credenciais externas.

3. Técnica escolhida: Chain of Thought

Chain of Thought consiste em estimular o modelo a "pensar" passo a passo antes de fornecer uma resposta direta, em vez de saltar diretamente para uma conclusão. Em um contexto clínico, essa técnica tem uma justificativa prática relevante: uma conclusão como "isso é um sinal de alerta" sem nenhuma justificativa é uma caixa-preta arriscada de se confiar. Ao instruir o modelo a listar os sintomas identificados e compará-los explicitamente com os critérios de alerta antes de concluir, a extração se torna auditável — alguém revisando a saída consegue verificar por que o modelo chegou àquela conclusão, não apenas qual foi a conclusão.

4. Fluxo implementado

- Baseline (sem CoT): o modelo recebe o texto clínico e é instruído a responder diretamente 'true' ou 'false' para a presença de um sinal de alerta, sem qualquer raciocínio intermediário.
- Com CoT: o modelo é instruído a retornar um JSON estruturado contendo (1) os sintomas identificados no texto, (2) uma comparação explícita de cada sintoma com os critérios de alerta (dor no peito, falta de ar, dor no braço, suor frio), e só então (3) a conclusão final.
- Validação: a saída de cada chamada é validada programaticamente com Pydantic, com nova tentativa em caso de JSON malformatado ou campo ausente.
- Execução em lote: as duas abordagens (com e sem CoT) foram aplicadas aos mesmos quatro relatos clínicos simulados, permitindo uma comparação direta lado a lado.

5. Resultados observados

A tabela a seguir apresenta os resultados reais obtidos ao executar o notebook sobre os quatro casos clínicos simulados, comparando a conclusão da abordagem sem CoT com a conclusão e o raciocínio da abordagem com CoT:

Caso	Sem CoT	Com CoT	Raciocínio gerado (trecho)
1	Verdadeiro	Verdadeiro	A dor torácica em aperto e a irradiação para o braço esquerdo batem com os critérios de alerta...
2	Falso	Falso	O sintoma de cansaço frequente ao subir escadas não bate com os critérios de alerta...
3	Falso	Falso	O sintoma de palpitações intermitentes não bate com os critérios de alerta...
4	Falso	Falso	O sintoma de inchaço nos tornozelos não bate com os critérios de alerta...

Os quatro casos foram desenhados para cobrir diferentes níveis de gravidade: o caso 1 apresenta sintomas explícitos de alerta (dor torácica com irradiação e sudorese fria), enquanto os casos 2 a 4 apresentam sintomas de rotina ou fatores de risco sem sinais de alerta diretos.

6. Discussão dos resultados

Um resultado importante a ser registrado com honestidade: nos quatro casos testados, a conclusão final não diferiu entre a abordagem sem CoT e a abordagem com CoT — ambas chegaram à mesma classificação (verdadeiro para o caso 1, falso para os demais), e ambas as classificações estão corretas em relação ao critério de gravidade definido no projeto.

Isso não invalida a técnica: o valor do Chain of Thought demonstrado aqui não está em corrigir uma classificação errada (nenhuma ocorreu nestes casos), mas em tornar a decisão auditável. Na abordagem sem CoT, obtém-se apenas um valor booleano, sem nenhuma pista sobre o motivo da classificação. Na abordagem com CoT, é possível verificar exatamente qual sintoma foi identificado e por que ele foi (ou não) considerado um sinal de alerta — uma propriedade valiosa em um contexto clínico, onde decisões automatizadas precisam poder ser revisadas por um humano. É esperado que a diferença entre as duas abordagens se torne mais evidente em casos clinicamente mais ambíguos do que os quatro testados, onde o raciocínio explícito do modelo teria maior chance de corrigir uma primeira impressão equivocada.

O caso 3 (palpitações intermitentes associadas a sedentarismo e obesidade) foi o caso limítrofe mais interessante do conjunto: não contém nenhum dos quatro sintomas de alerta explícitos, mas apresenta fatores de risco cardiovasculares. É exatamente neste tipo de caso que o raciocínio explícito mais se justifica, pois permite verificar que a ausência de classificação como emergência se deu pela ausência dos sintomas-critério, e não por uma omissão do fator de risco.

7. Conexão com a Parte 1 do projeto

O campo de conclusão da extração reaproveita o mesmo critério de gravidade utilizado na action "Relatar sintoma" do watsonx Assistant (Parte 1): dor no peito, falta de ar, dor no braço e suor frio como

sinais de alerta. A diferença está na origem da informação: na Parte 1, o usuário responde a perguntas estruturadas dentro de um fluxo de diálogo fixo; nesta extensão, o mesmo critério é aplicado a partir de um texto livre não estruturado, com a vantagem adicional de expor o raciocínio por trás da decisão.

8. Conclusão

A extensão demonstrou a aplicação da técnica de Chain of Thought para extração estruturada de informações clínicas a partir de texto livre, com validação programática da saída e comparação direta contra uma abordagem sem raciocínio explícito. Embora a conclusão final não tenha divergido entre as duas abordagens nos casos testados, o Chain of Thought agregou um valor concreto de auditabilidade, permitindo verificar o porquê de cada classificação — uma propriedade especialmente relevante em aplicações de saúde, onde a confiança em uma decisão automatizada depende da possibilidade de revisá-la.